

Gustavo Stein Santos Mattos Araújo dos Santos Humberto da Silva Neto

# **Agenda**

- Redes Auto-organizáveis de Kohonen
  - \*Introdução
  - Características
  - \* Funcionamento
- Aplicações
- Implementação
  - \*SOMTF
  - **SOMPY**
  - \* Testes
  - Problema proposto e resultados

# Redes Auto-organizáveis de Kohonen

# Introdução

- Proposta por Teuvo Kohonen, 1982
- Inspiração biológica no córtex cerebral
- Aprendizado competitivo
- Estrutura reticulada



### Características

#### **Redes Neurais usuais**

- \*Série de camadas
- Correção por erro
- Aprendizado supervisionado


#### SOM

- ❖Rede 2D\*
- Por competição
- Aprendizado não supervisionado



# Características

- Adapta-se à organização topológica de um dataset, permitindo a visualização de cluster's em potencial
- Lida melhor com variáveis contínuas



# Características

#### **Vantagens**

- Representação visual (Redução da dimensionalidade)
- Organização de dados de forma a tornar inferências sobre os mesmos possível
- Grande número de variáveis

#### **Desvantagens**

- Não lida bem com variáveis categóricas
- Computacionalmente dispendiosa
- Soluções nem sempre facilmente correlacionáveis

# **Funcionamento: treinamento**

Definir mapa topológico

Definir vizinhança

σ

Obter conjunto de amostras

X

Inicializar o vetor de pesos

W

NORMALIZAR OS VETORES!

TREINAMENTO

Identificar as regiões correspondentes



Encontrar o neurônio vencedor


Ajustar o vetor de pesos

$$w^{(v)} \leftarrow w^{(v)} + \eta(x^{(k)} - w^{(v)})$$

$$w^{(\Omega)} \leftarrow w^{(\Omega)} + \eta^* \alpha^{(\Omega)} (w^{(v)} - w^{(\Omega)})$$


$$\alpha^{(\Omega)} = \exp(-||\mathbf{W}(\mathbf{v}) - \mathbf{W}(\Omega)||^2/2\sigma^2)$$

# Funcionamento: treinamento



Step 0: Position neurons (orange) in data space.

# Funcionamento: agrupamento



# Funcionamento: algoritmos

#### Início (Algoritmo Kohonen – Fase de Treinamento)

- ∫<1> Definir o mapa topológico da rede;
- <2> Montar os conjuntos de vizinhança  $\{\Omega^{(j)}\}$ ;
- <3> Iniciar o vetor de pesos de cada neurônio  $\{\boldsymbol{w}^{(j)}\}$  considerando os valores das  $n_1$  primeiras amostras de treinamento;
- <4> Obter o conjunto de amostras de treinamento {  $\mathbf{x}^{(k)}$  };
- <5> Normalizar os vetores de amostras e de pesos;
- <6> Especificar a taxa de aprendizagem  $\{ \eta \}$ ;
- <7> Iniciar o contador de número de épocas { época ← 0 };
- <8> Repetir as instruções:
  - (<8.1> Para todas as amostras de treinamento {  $\boldsymbol{x}^{(k)}$ }, fazer:
    - (-8.1.1) Calcular as distâncias euclidianas entre  $x^{(k)}$  e  $\mathbf{w}^{(j)}$ , conforme a expressão (8.1);
    - <8.1.2> Declarar como vencedor o neurônio *j* que contenha a menor distância euclidiana:

$$vencedor = arg \min_{i} \{ || \mathbf{x}^{(k)} - \mathbf{w}^{(j)} || \}$$

- <8.1.3> Ajustar o vetor de pesos do vencedor, conforme a regra 1 da expressão (8.4);
- <8.1.4> Ajustar o vetor de pesos dos neurônios vizinhos ao vencedor, definidos em  $\Omega^{(j)}$ , conforme regra 2 da expressão (8.4) ou (8.5);
- <8.1.5> Normalizar o vetor de pesos que foi ajustado na instrução anterior;
- \ <8.2> época ← época + 1;

Até que: não haja mudanças significativas nos vetores de pesos;

- <9> Analisar o mapa visando extração de características;
- <10> Identificar regiões que possibilitem a definição de classes.

#### Fim {Algoritmo Kohonen – Fase de Treinamento}


#### Início (Algoritmo Kohonen – Fase de Operação)

- <1> Apresentar a amostra { x } a ser classificada e normalizar;
- <2> Assumir os vetores de pesos  $\{ \mathbf{w}^{(j)} \}$  já ajustados durante a fase de treinamento;
- <3> Executar as seguintes instruções:
  - <3.1> Calcular as distâncias euclidianas entre  $\mathbf{x}$  e  $\mathbf{w}^{(j)}$ , conforme a expressão (8.1);
  - <3.2> Declarar como vencedor o neurônio *j* que contenha a menor distância euclidiana:
  - <3.3> Localizar o neurônio vencedor dentro do mapa autoorganizável;
  - <3.4> Associar a amostra à classe que foi identificada a partir da confecção do mapa de contexto;
- <4> Disponibilizar a eventual classe em que a amostra foi associada.


#### Fim {Algoritmo Kohonen – Fase de Operação}



# Classificação de países por condição socioeconômica



# Classificação de países por condição socioeconômica




### Similaridade em Textos

- 80% dos textos obtidos em datamining não são estruturados ou catalogados
- Combinação de PNL com SOM's para sintetização e classificação de textos

```
title 15
          Ultramar 64 versus 42
                                   versus 50 DATELINE 28
           Sterling 18 loss 33
                                    cent 25
 blah 14
                                                 cent 24
 Blah 14
                       profit 32 DATELINE 20
                                                 div 24
             loss 8
TITLE 14
               z 8
                         cent 19
                                    share 18
                                                record 18
      title 16
                   loss 57
                              versus 50
                                         coffee 10
                 versus 30 DATELINE 10 guota 8
       blah 16
       Blah 16
                   Net 13
                               cent 9
                                         delegate 8
                               Sales 8
      TITLE 16
                   cent 11
                                          price 7
title 20 correction 22 Oper 40
                                    Oper 44
                                              dividend 22
 blah 19
             read 15
                         loss 37
                                   versus 39
                                               declare 12
 Blah 19
           correct 11 versus 32
                                     net 20
                                                split 11
TITLE 19 paragraph 10 cent 17
                                    cent 18
                                                split 11
                  franc 36 earnings 10 share 16
       bond 14
       issue 10
                issue 5
                              dollar 9 offering 10
                              quarter 8
      percent 8
                   bond 4
                                          prefer 8
      manager 7
                              report 6
                   issue 4
                                          stock 6
           percent 16
                                    acquire 6
 bank 17
                         sale 21
                                                 offer 9
                          car 9
                                 acquisition 6
Sterling 7
             rise 5
                       percent 5
 loan 4
             year 5
                                    merger 5
                                                 stake 6
             rose 5
                         year 5
 rate 4
                                      Inc 4
                                                 aroup 4
                   plant 7
                               unit 6
                                          trade 10
      Reagan 3
                  strike 6
                              venture 4 exchange 7
       trade 3
                    ton 6
                                Inc 3
                                          future 6
                   gold 5
                             agreement 3 stock 4
       Japan 3
 tonne 22
                       contract 10 president 14debenture 14
              oil 9
 wheat 6
            barrel 8
                        system 4
                                   officer 11
            reserve 6 computer 3 chairman 9subordinate
 sugar 4
                                    resign 7
 corn 3
             OPEC 4
                         order 3
                                               offering 6
```

# Diagnóstico de Cancer de Mama

A intensidade e textura de uma anomalia pode ser usada para classificar a mesma como maligna ou benigna





### SOMTF

```
@ Ⅲ ···
      somtf.py ×
             import tensorflow as tf
             import numpy as np
             class SOM(object):
               2-D Self-Organizing Map with Gaussian Neighbourhood function and linearly decreasing learning rate.
8
               trained = False
Ů,
               def __init__(self, m, n, dim, n_iterations = 100, alpha=.1, sigma=None, decay_in_time = True):
                Initializes all necessary components of the TensorFlow Graph
                  m: map width
                  n: map height
                  dim: dimension of the input vector
                  alpha: initial value of the learning rate - Default value is 0.1
                  sigma: initial value of neighborhood radius - Default value is max(m, n)/2
                  decay in time: decay the learning rate value through time
                 self. m = m
                self._n_iterations = int(n_iterations)
                 alpha = float(alpha)
                if sigma is None:
                  sigma = max(m,n)/2.0
                  sigma = float(sigma)
                 if decay in time is not True:
                  decay_in_time = False
Ln 54, Col 28 Spaces: 2 UTF-8 LF Python 😃
```


https://github.com/hsneto/redes neurais/blob/master/neural networks/somtf.py

### **SOMPY**


```
sompy.py ×
             import numpy as np
Q
             class SOM(object):
8
              2-D Self-Organizing Map with Gaussian Neighbourhood function and linearly decreasing learning rate.
8
              trained = False
              def __init__(self, m, n, dim, n_iterations = 100, alpha=.1, sigma=None, decay_in_time = True):
Ů.
                Initializes all necessary components of the TensorFlow Graph
                  m: map width
                  n: map height
                  dim: dimension of the input vector
                  n iterations: number of iterations (epochs) - Default value is 100
                  alpha: initial value of the learning rate - Default value is 0.1
                  sigma: initial value of neighborhood radius - Default value is max(m, n)/2
                  decay in time: decay the learning rate value through time
                self._m = m
                self. n = n
                self. dim = dim
                self._n_iterations = int(n_iterations)
                self. alpha = float(alpha)
                if sigma is None:
                  self.\_sigma = max(m,n)/2.0
                  self._sigma = float(sigma)
                self. decay in time = True
                if decay_in_time is not True:
                  self._decay_in_time = False
Ln 52, Col 8 Spaces: 2 UTF-8 LF Python 😃
```

https://github.com/hsneto/redes neurais/blob/master/neural networks/sompy.py

- **⋄** m = 20
- **⋄** dim = 3
- n\_interations = 400
- ❖ alpha = 0.5
- sigma = None
- decay\_in\_time = True




- **⋄** m = 20
- dim = 3
- n\_interations = 400
- alpha = 0.1
- ❖ sigma = None
- decay\_in\_time = True




- **⋄** m = 20


- n\_interations = 400
- alpha = 1.0
- sigma = None
- decay\_in\_time = True




- **⋄** m = 20
- n = 30
- dim = 3
- n\_interations = 400
- ❖ alpha = 0.5
- decay\_in\_time = True




- ❖ n = 15
- dim = 3
- n\_interations = 400
- ❖ alpha = 0.5
- sigma = None
- decay\_in\_time = True



- ❖ n = 60
- n\_interations = 400
- ❖ alpha = 0.5
- sigma = None
- decay\_in\_time = True




- **⋄** m = 20
- n = 30
- n\_interations = 100
- alpha = 0.1
- sigma = None
- decay\_in\_time = True




- **⋄** m = 20

- n\_interations = 1000
- alpha = 0.1
- ❖ sigma = None
- decay\_in\_time = True






- n = 30
- **⋄** dim = 3
- n\_interations = 400
- ❖ alpha = 0.5
- sigma = None
- decay\_in\_time = False




# Problema proposto

- No processo de identificação de pneus:
  - Identificar eventuais similaridades e correlações entre as variáveis que fazem parte do processo de fabricação de pneus
- Mapa de Kohonen:
  - Com 16 neurônios
  - $*\eta = 0.001$
  - Vizinhança unitária
  - 3 classes distintas
    - ❖ A 20 amostras
    - ❖ B 40 amostras
    - ❖ C 60 amostras

# Resultado: treino





# Resultado: teste




	<b>x1</b>	<b>x2</b>	х3
0	0.2471	0.1778	0.2905
1	0.8240	0.2223	0.7041
2	0.4960	0.7231	0.5866
3	0.2923	0.2041	0.2234
4	0.8118	0.2668	0.7484
5	0.4837	0.8200	0.4792
6	0.3248	0.2629	0.2375
7	0.7209	0.2116	0.7821
8	0.5259	0.6522	0.5957
9	0.2075	0.1669	0.1745
10	0.7830	0.3171	0.7888
11	0.5393	0.7510	0.5682

# Resultado: comparações






# Resultado: comparações



# Resultado: comparações



### Referências

- Ivan Silva, Danilo Spatti and Rogério Fluzino "Redes Neurais Artificiais para engenharia e ciências aplicadas", Artliber, 2010
- http://blog.yhat.com/posts/self-organizing-maps-1.html
- http://www.ai-junkie.com/ann/som/som1.html
- https://vahidmoosavi.com/2014/02/18/a-self-organizing-map-som-package-in-python-sompy/
- https://codesachin.wordpress.com/2015/11/28/self-organizingmaps-with-googles-tensorflow/
- http://www.decom.ufop.br/imobilis/self-organizing-maps/
- https://bop.unibe.ch/linguistik-online/article/view/788/1355